



TRAKYA ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

YAPAY SİNİR AĞLARI
PROJE RAPORU

PROJE ADI:

Türkçe Gürültü Temizleme Uygulaması (SLESS)

PROJE EKİBİ:

1221602052 – Bayram Çağlar KAPTAN

1221602054 – Berk VARA O.

1221602061 – Bilal ÇETİN

1221602055 – Eren Arda ÇOLAK

1221602095 – Zülfükar Can USTA

PROJE DANIŞMANI:

Dr. Öğr. Üyesi Turgut Doğan

Edirne – 2026

İÇİNDEKİLER

1. GİRİŞ VE PROJENİN TANITIMI	3
1.1. Projenin Konusu ve Amacı	3
1.2. Projenin Kapsamı	4
1.3. Benzer Çalışmalar	4
2. GEREKSİNİM ANALİZİ	5
2.1. Hedef Platformlar	5
2.2. Hedef Kitle ve Kullanıcı Roller	6
2.3. Kullanılan Araç ve Teknolojiler	6
2.3.1. Kullanılan Teknolojiler ve Tercih Sebepleri	6
2.3.2. Projede Kullanılan Araçlar	7
2.3.3. Projede Kullanılan Model Mimarileri	8
2.3.4. Projede Kullanılan Model Karşılaştırma Metrikleri	10
2.3.5. Projede Kullanılan Veri Setleri	11
2.3.6. Geliştirilen Modeller ve Karşılaştırmalı Sonuçları	13
2.4. Genel Değerlendirme ve Nihai Tercihler	22
3. TASARIM	23
3.1. Sistem Mimarisi ve Bileşenleri	23
3.1.1. Kullanıcı Arayüzü	23
3.1.2. Ses İşleme ve İş Akışı Katmanı	23
3.1.3. Model Erişim Katmanı	24
3.1.4. Girdi Hazırlama ve Modele Besleme	25
3.1.5. Çıktı Üretimi ve Post-Processing	25
3.2. Ekranlar	25

3.2.1.	Ses Temizleme Ekranı	25
3.2.2.	Model Karşılaştırma Ekranı	28
3.2.3.	Geçmiş Ekranı	30
4.	TEST VE DOĞRULAMA	33
4.1.	Test ve Hata Giderme Mekanizmaları	33
4.2.	Geliştirme Sürecinde Karşılaşılan Hatalar ve Çözümleri	33
4.3.	Genel Değerlendirme	35
5.	SONUÇ	35
5.1.	Modellerin Test Çıktıları	37
5.2.	Genel Kazanımlar	39
5.3.	GitHub	40
6.	KAYNAKLAR	40

1. GİRİŞ VE PROJENİN TANITIMI

1.1. Projenin Konusu ve Amacı

Bu proje, derin öğrenme tabanlı konuşma gürültü giderme (speech enhancement / denoising) modellerinin Türkçe ses verileri üzerinde performansını karşılaştırmalı olarak değerlendirmeyi amaçlamaktadır. Günümüzde gürültü giderme modelleri büyük ölçüde İngilizce veri kümeleri ile eğitilmekte olup Türkçe konuşma sesine özgü fonetik yapılar göz ardı edilmektedir. Türkçe, ünlü uyumu, sondan eklemeli yapı ve kendine özgü ünsüz dizilişleri bakımından İngilizceden belirgin biçimde ayrılmaktadır. Bu farklılıklar, İngilizce üzerinde eğitilmiş bir gürültü giderme modelinin Türkçe sesi işlerken bazı fonetik bileşenleri gürültü olarak sınıflandırmasına yol açabilmektedir.

Projenin temel amacı, ön eğitilmiş gürültü giderme modellerini Türkçe konuşma verileriyle ince ayar yaparak bu fonetik özelliklerin modele kazandırılması ve böylece Türkçede doğru ve kaliteli biçimde çalışan bir konuşma gürültü giderme sistemi ortaya koymaktır. Bu süreçte

birden fazla model mimarisi aynı veri kümesi ve aynı değerlendirme koşulları altında karşılaştırılarak hangi yaklaşımın Türkçe ses için daha uygun olduğu nesnel ve öznel yöntemlerle incelenmiştir.

1.2. Projenin Kapsamı

Proje kapsamında geliştirilen sistem, aşağıdaki aşamalardan oluşan çok bileşenli bir işlem hattı üzerine kuruludur.

İlk aşamada Türkçe konuşma verisi derlenmiştir. Google FLEURS (tr_tr) veri kümesinden yaklaşık 2.000 ve CommonVoice 17 TR veri kümesinden 12.000 olmak üzere toplam 14.000 temiz Türkçe ses dosyası hazırlanmıştır. Tüm dosyalar 16 kHz örnekleme hızına dönüştürülmüş, mono kanala indirgenmiş ve tepe normalizasyonu uygulanmıştır.

İkinci aşamada gürültü augmentation yapılmıştır. Microsoft DNS Challenge 4 veri kümesinden elde edilen 659 gerçek ortam gürültüsü, her temiz ses dosyasına -5 dB ile +20 dB arasında 6 farklı sinyal-gürültü oranında (SNR) eğitim sırasında anlık olarak üretilerek karıştırılmıştır. Bu yaklaşım sabit gürültülü-temiz çiftleri önceden oluşturmak yerine her eğitim adımında farklı kombinasyonlar ürettiğinden veri çeşitliliğini artırmış ve aşırı öğrenmeyi azaltmıştır.

Üçüncü aşamada nesnel ve öznel değerlendirme yapılmıştır. SI-SDR (Signal-to-Distortion Ratio), PESQ (Perceptual Evaluation of Speech Quality) ve STOI (Short-Time Objective Intelligibility) metrikleri ile nesnel ölçümler gerçekleştirilmiş, elde edilen temizlenmiş sesler dinleme testiyle öznel olarak da değerlendirilmiştir.

1.3. Benzer Çalışmalar

Konuşma gürültü giderme alanında kullanıcıya yönelik çeşitli ticari ve açık kaynak çözümler mevcuttur.

NVIDIA RTX Voice ve NVIDIA Broadcast, NVIDIA'nın yapay zeka destekli gürültü giderme ürünleridir. Özellikle oyun ve yayın sektöründe yaygın kullanılan bu araçlar gerçek zamanlı gürültü giderme konusunda başarılı sonuçlar vermektedir. Ancak NVIDIA GPU gerektirmeleri, yalnızca Windows platformunda çalışmaları ve Türkçe konuşmaya özel bir optimizasyon içermemeleri temel kısıtlarıdır.

Krisp, bulut tabanlı AI gürültü giderme hizmeti sunan ticari bir platformdur. Toplantı ve sesli iletişim uygulamalarına entegrasyon kolaylığı ile öne çıkmaktadır. İngilizce ağırlıklı eğitim

verisiyle geliştirilmiş olması, Türkçe konuşmada performansın garanti edilmediği anlamına gelmektedir.

Adobe Podcast Enhance ve Adobe Audition, ses prodüksiyon alanında Adobe'nin sunduğu gürültü giderme araçlarıdır. Yüksek kaliteli çıktılar üretebilmekle birlikte abonelik gerektiren kapalı kaynak ürünlerdir ve belirli bir eğitim veri setine dayalı genel amaçlı modeller kullandıklarından dile özgü ince ayar içermemektedir.

Zoom, Microsoft Teams ve Google Meet gibi video konferans platformları da yerleşik gürültü giderme özellikleri sunmaktadır. Bu özellikler günlük kullanımda yeterli sonuçlar verse de akademik veya profesyonel ses kalitesi standartlarını karşılayamamakta ve yine İngilizce ağırlıklı verilerle geliştirilmiş genel modellerdir.

Bu projeyi söz konusu çözümlerden ayıran temel özellik, modellerin Türkçe konuşma verileriyle ince ayara tabi tutulmasıdır. Piyasadaki mevcut çözümlerin hiçbiri Türkçeye özgü fonetik yapıyı hedef alan sistematik bir eğitim süreci içermemektedir.

2. GEREKSİNİM ANALİZİ

2.1. Hedef Platformlar

Projenin hedef platformları, modelin eğitim sürecinden son kullanıcıya ulaşacağı dağıtım ortamına kadar farklı katmanları kapsamaktadır.

Eğitim ve geliştirme aşamasında Google Colab Pro+ ortamı kullanılmaktadır. NVIDIA A100 (40GB VRAM) GPU ile büyük model mimarileri ve uzun süreli eğitimler gerçekleştirilmiştir. Eğitilen model ağırlıkları ve loglar Google Drive üzerinde saklanarak Colab oturumunun kapanmasından bağımsız biçimde kalıcı hale getirilmiştir.

Hem eğitim verileri hem de kullanılan açık kaynak model mimarileri / ağırlıkları HuggingFace Hub ve GitHub üzerinden sağlanmıştır. FullSubNet+, MossFormerGAN, FRCRN, GTCRN ve SGMSE+ mimarileri proje kapsamında değerlendirilmiştir.

Son kullanıcıya yönelik dağıtım platformu olarak web tabanlı bir uygulama hedeflenmektedir. React ile geliştirilen ön yüz, kullanıcıdan gürültülü ses dosyası alarak FastAPI tabanlı Python

arka ucuna iletmektedir. Arka uç, ilgili modeli çalıştırarak temizlenmiş ses dosyasını kullanıcıya döndürmektedir.

2.2. Hedef Kitle ve Kullanıcı Roller

Projenin hedef kitlesi, Türkçe konuşma içeren ses kayıtlarında arka plan gürültüsünden kaynaklanan kalite sorunuyla karşılaşan bireyler ve kurumlar olarak tanımlanabilir.

Bireysel kullanıcılar arasında podcast yayıncıları, içerik üreticileri, öğrenciler ve uzaktan çalışanlar öne çıkmaktadır. Ev ortamında, açık alanda veya gürültülü ofislerde kaydedilen ses içeriklerinin temizlenmesi bu kullanıcılar için önemli bir ihtiyaçtır. Mevcut ticari çözümlerin Türkçe fonetik yapısını yeterince tanınamaması, bu kitleye yönelik Türkçe odaklı bir çözümün gerekliliğini ortaya koymaktadır.

Kurumsal kullanıcılar arasında çağrı merkezleri, hukuk büroları, yayın kuruluşları ve eğitim platformları yer almaktadır. Bu kurumlarda Türkçe konuşma kayıtlarının arşivlenmesi, transkript oluşturulması veya yayına hazırlanması süreçlerinde ses kalitesi kritik öneme sahiptir.

Sistem iki temel kullanıcı rolü üzerine tasarlanmıştır. Son kullanıcı gürültülü ses dosyasını web arayüzüne yükler, model tarafından temizlenen sesi dinler ve indirir. Geliştirici veya sistem yöneticisi ise veri hazırlama, model fine-tuning, checkpoint yönetimi, metrik değerlendirme ve backend servis yönetimi gibi teknik süreçlerden sorumludur.

2.3. Kullanılan Araç ve Teknolojiler

2.3.1. Kullanılan Teknolojiler ve Tercih Sebepleri

Python 3.12, projenin model geliştirme, veri hazırlama, eğitim ve değerlendirme süreçlerinde temel programlama dili olarak kullanılmıştır. PyTorch, HuggingFace Datasets, SpeechBrain ve SoundFile gibi derin öğrenme ve ses işleme kütüphaneleriyle güçlü entegrasyonu tercih sebebi olmuştur.

PyTorch 2.x, model eğitimi ve inference işlemleri için kullanılmıştır. Dinamik hesaplama grafiği, mixed precision (AMP) ve gradient clipping gibi özellikler eğitim kararlılığını artırmıştır. torchaudio kütüphanesi ise STFT/iSTFT dönüşümleri ve örnekleme hızı standardizasyonu için kullanılmıştır.

HuggingFace Datasets, Google FLEURS tr_tr ve CommonVoice 17 TR veri kümelerine streaming ve batch modunda erişim sağlamak için tercih edilmiştir. Büyük veri kümelerinin tamamını indirmeden işlenebilmesi bellek verimliliği açısından önemli avantaj sağlamıştır.

SoundFile kütüphanesi ses dosyalarının okunması ve yazılması, librosa ise ses analizi ve özellik çıkarımı için kullanılmıştır. Tüm ses dosyaları 16 kHz örnekleme hızına ve mono kanala bu araçlar aracılığıyla dönüştürülmüştür.

PESQ ve PYSTOI, eğitilen modellerin nesnel değerlendirilmesinde kullanılan metrik kütüphaneleridir. PESQ insan algısına yakın algısal kalite skoru üretirken STOI konuşma anlaşılabilirliğini ölçmektedir.

FastAPI, eğitilmiş modelleri web ortamında servis etmek için hafif ve yüksek performanslı bir REST API çerçevesi olarak seçilmiştir. React ise kullanıcı arayüzü için tercih edilen bileşen tabanlı modern web çerçevesidir.

2.3.2. Projede Kullanılan Araçlar

Google Colab Pro+, model eğitimlerinde yüksek performanslı GPU kaynaklarına erişim sağlamak için kullanılmıştır. A100 GPU ortamı, büyük model mimarileri ve uzun süreli eğitimler için tercih edilirken T4 GPU daha küçük modellerin test aşamasında kullanılmıştır.

Git ve GitHub, kullanılan model repolarının indirilmesi ve geliştirme sürecinin yönetilmesi için kullanılmıştır. FullSubNet+, ClearerVoice-Studio (MossFormerGAN) ve SpeechBrain gibi açık kaynak model mimarileri GitHub üzerinden projeye dahil edilmiştir.

Jupyter Notebook, veri hazırlama, eğitim, test ve hata ayıklama süreçlerinin hücreler halinde yönetilebilmesi için kullanılmıştır. Hiperparametre denemeleri, metrik izleme ve ses dosyalarının Colab ortamında doğrudan dinlenerek değerlendirilmesi notebook ortamında gerçekleştirilmiştir.

HuggingFace Hub, hem veri kümelerine erişim hem de pretrained model ağırlıklarının indirilmesi için kullanılmıştır. FLEURS, CommonVoice 17 TR ve MossFormerGAN pretrained checkpoint bu platform üzerinden sağlanmıştır

2.3.3. Projede Kullanılan Model Mimarileri

Proje kapsamında beş farklı derin öğrenme mimarisi Türkçe ses verisiyle eğitilmiş ve karşılaştırılmıştır. Mimariler seçilirken yaklaşım çeşitliliği ön planda tutulmuştur: zaman-frekans alanında maske tahmini, kompleks spektrogram işleme, transformer tabanlı öğrenme ve GAN destekli üretici model gibi birbirinden farklı yöntemler bir arada değerlendirilmiştir.

FullSubNet+

FullSubNet+, tam bant ve alt bant bilgisini birleştiren LSTM tabanlı hibrit bir mimaridir. Modelin temel çalışma prensibi şöyledir: gürültülü ses önce STFT ile frekans-zaman temsiline dönüştürülür. Tam bant modeli tüm frekans bandını bir bütün olarak işleyerek genel gürültü örüntüsünü öğrenirken alt bant modeli her frekans bandının komşularıyla birlikte yerel özelliklerini öğrenir. Bu iki modelin çıktıları birleştirilip kompleks ideal oran maskesi (cIRM) tahminine dönüştürülür. Maske gürültülü spektrograma uygulanarak temizlenmiş ses elde edilir.

MossFormerGAN_SE_16K

MossFormerGAN, MossFormer2 mimarisini temel alan ve buna Üretici Çekişmeli Ağ (GAN) eğitimini entegre eden bir modeldir. MossFormer2 çekirdeği, Gated Single-Head Transformer bloklarını Feed-forward Sequential Memory Network (FSMN) katmanlarıyla birleştirerek hem uzun menzilli bağımlılıkları hem de kısa menzilli yerel örüntüleri öğrenebilmektedir. Transformer'ın dikkat mekanizması gürültünün bağlamsal yapısını modellerken FSMN katmanları hızlı yerel geçiş özelliklerini yakalar.

GAN bileşeni modele algısal kalite boyutu katar. Üretici temizlenmiş ses üretirken ayrımcı gerçek temiz ses ile üretilen ses arasındaki farkı öğrenir. Bu çekişmeli eğitim sonucunda model matematiksel metrikler yerine insan kulağına daha yakın sesler üretmeye yönelir. Yaklaşık 25 milyon parametresiyle gruptaki en büyük modeldir.

FRCRN

FRCRN (Frequency Recurrent Complex-valued U-Net), kompleks spektrogram üzerinde doğrudan çalışan bir modeldir. Geleneksel yaklaşımlar ses sinyalinin yalnızca genliğini

işlerken FRCRN hem genlik hem faz bilgisini aynı anda işleyerek daha eksiksiz bir spektral temsil sağlar.

Mimari olarak U-Net yapısını temel alır. Kodlayıcı (encoder) gürültülü kompleks spektrogramı aşamalı olarak soyutlayarak özellik haritaları üretirken kod çözücü (decoder) bu özelliklerden temizlenmiş spektrogramı yeniden inşa eder. Kodlayıcı ve kod çözücü katmanları arasındaki kısayol bağlantıları (skip connections) ince detayların korunmasını sağlar. Geri yinelemeli konvolüsyon katmanları zamansal bağımlılıkları öğrenmek için kullanılır.

GTCRN

GTCRN (Gated Temporal Convolutional Recurrent Network), düşük gecikme süresiyle gerçek zamanlı uygulamalar için tasarlanmış bir modeldir. Grup gecikmeli konvolüsyon katmanları, farklı frekans gruplarının farklı zaman gecikmelerini öğrenmesine olanak tanıyarak frekans-zaman düzleminde daha zengin bir temsil elde edilmesini sağlar.

Kapılı mekanizma, modelin hangi bilginin ileriye taşınacağına ve hangisinin filtreleneceğine öğrenme sürecinde karar vermesini mümkün kılar, bu LSTM'deki hücre durumu fikrine benzer ancak konvolüsyon tabanlıdır. Yinelemeli katmanlar ise zamansal bağımlılıkları öğrenmek için kullanılır. GTCRN bu projede sıfırdan eğitilmiş ve yaklaşık 6.9 milyon parametresiyle gruptaki en hafif model olmuştur.

SGMSE+

SGMSE+, skor tabanlı üretici modelleme yaklaşımından ilham alınarak geliştirilen ve difüzyon sürecini ses iyileştirme görevine uyarlayan bir model mimarisidir. Geleneksel maskele-ve-uygula yaklaşımının aksine, gürültülü sesi küçük adımlarla bir geri difüzyon süreciyle adım adım temiz sese yaklaştırmayı hedefler. Modelin çekirdeği, zaman gömme katmanlarıyla desteklenmiş bir U-Net tarzı kodlayıcı-çözücü yapısından oluşmaktadır. Kodlayıcı gürültülü sinyali aşamalı olarak soyutlayarak özellik haritaları üretirken çözücü bu özelliklerden temizlenmiş sinyali yeniden inşa eder. Zaman gömme katmanları ise difüzyon sürecinin hangi adımında olduğunu modele aktararak küçük adımlarla iyileştirme sürecinin düzenlenmesine katkı sağlar.

Bu mimari yaklaşımın temel avantajı, tek bir ileri geçişle çıktı üretmek yerine gürültü dağılımını kademeli olarak düzelterek daha doğal ve yapay bozulmasız ses elde edebilmesidir. Projede SGMSE+ sıfırdan eğitilmiştir.

2.3.4. Projede Kullanılan Model Karşılaştırma Metrikleri

Eğitilen modellerin performansını nesnel olarak değerlendirmek için sinyal işleme ve konuşma kalitesi literatüründe yaygın kabul gören üç metrik kullanılmıştır. Bu metriklerin her biri farklı bir kalite boyutunu ölçmekte olup birlikte kullanıldığında modelin hem matematiksel hem de algısal performansı hakkında kapsamlı bir değerlendirme imkânı sunmaktadır.

SI-SDR (Scale-Invariant Signal-to-Distortion Ratio)

SI-SDR, tahmin edilen sinyalin hedef sinyale ne kadar yakın olduğunu ölçen bir sinyal-gürültü oranı metriğidir. Geleneksel SDR metriğinin ölçek değişmezliği sağlanmış halidir; yani iki sinyal arasındaki yalnızca ölçek farkı skoru etkilememektedir. Hesaplama prensibi şu şekildedir: tahmin edilen sinyal önce sıfır ortalamalı hale getirilir, ardından hedef sinyale olan projeksiyon bileşeni ile bu projeksiyondan artan gürültü bileşeni ayrıştırılarak bu ikisinin güç oranının logaritması alınır. Sonuç desibel cinsinden ifade edilir.

Yorumlama açısından yüksek SI-SDR değeri modelin hedef sinyali daha doğru ürettiği anlamına gelir. Bu projede hem gürültülü giriş sesinin SI-SDR değeri hem de model çıktısının SI-SDR değeri hesaplanmış; ikisi arasındaki fark modelin sağladığı iyileştirmeyi göstermek için raporlanmıştır. Genel kabul gören eşikler açısından +8 dB üzeri iyileştirme iyi, +12 dB üzeri çok iyi olarak değerlendirilmektedir.

SI-SDR'ın önemli bir kısıtı, insanın ses kalitesini algılama biçimiyle her zaman örtüşmemesidir. Matematiksel olarak yüksek SI-SDR değeri elde eden bir model, kulağa hâlâ yapay veya bozuk gelebilir. Bu nedenle SI-SDR tek başına yeterli değildir ve aşağıdaki metriklerle birlikte değerlendirilmesi gerekmektedir.

PESQ (Perceptual Evaluation of Speech Quality)

PESQ, ITU-T P.862 standardı kapsamında tanımlanmış ve telekomünikasyon sistemlerinde konuşma kalitesini nesnel olarak değerlendirmek için geliştirilmiş bir metriktir. İnsan kulağının ses kalitesini nasıl algıladığını modelleyen bir referans sinyalle karşılaştırma yöntemi kullanır.

Geniş bant modda 1.0 ile 4.5 arasında bir skor üretir; 1.0 anlaşılması çok güç bir sesi, 4.5 ise neredeyse mükemmel kaliteyi temsil etmektedir.

PESQ'nun temel avantajı, insan dinleme testleriyle yüksek korelasyon göstermesidir. Bu nedenle modelin gerçek kullanım senaryolarındaki kalitesini tahmin etmede SI-SDR'a kıyasla daha güvenilir bir gösterge niteliğindedir. Bu projede 2.5 üzeri iyi, 3.0 üzeri çok iyi olarak referans alınmıştır. DNS Challenge yarışmasında öne çıkan modeller genellikle PESQ 3.0 üzerinde değerlere ulaşmaktadır.

STOI (Short-Time Objective Intelligibility)

STOI, konuşma anlaşılabilirliğini ölçen bir metriktir. Temizlenmiş sesin ne kadar net ve anlaşılır olduğunu değerlendirmek için kısa süreli Fourier dönüşümü tabanlı bir çerçevede referans sinyal ile tahmin sinyali karşılaştırılır. Skor 0 ile 1 arasında değer alır; 1'e yakın değerler yüksek anlaşılabilirliği ifade eder.

PESQ genel ses kalitesini ölçerken STOI özellikle konuşmanın kelime bazında anlaşılabilirliğine odaklanır. Gürültü giderme sonucunda sese eklenen yapay bozulmalar PESQ'yu düşürebilirken STOI yüksek kalabilir ya da tersi gerçekleşebilir. Bu nedenle ikisinin birlikte değerlendirilmesi modelin gerçek performansını daha eksiksiz biçimde ortaya koyar. Bu projede 0.85 üzeri iyi, 0.90 üzeri çok iyi referans eşik olarak alınmıştır.

2.3.5. Projede Kullanılan Veri Setleri

Proje kapsamında modellerin eğitimi ve değerlendirilmesi için iki farklı türde veri kümesine ihtiyaç duyulmuştur: temiz Türkçe konuşma verisi ve gürültü verisi. Temiz konuşma verisi modelin öğrenmesi gereken hedef sinyali temsil ederken gürültü verisi augmentation aşamasında temiz seslerle karıştırılarak gerçek dünya koşullarını simüle eden gürültülü-temiz çiftleri oluşturmak için kullanılmıştır.

Google FLEURS (tr_tr)

FLEURS (Few-shot Learning Evaluation of Universal Representations of Speech), Google tarafından geliştirilen ve 102 dili kapsayan çok dilli bir konuşma veri kümesidir. Türkçe bölümü (tr_tr) train, validation ve test olmak üzere üç split'ten oluşmakta ve toplamda yaklaşık 3.607 eşsiz ses kaydı içermektedir. Kayıtlar profesyonel düzeyde temiz ortamda alınmış,

standart Türkçe metinlerin okunmasıyla oluşturulmuştur. Bu nedenle düşük gürültü seviyesi ve tutarlı kayıt kalitesiyle eğitim için sağlam bir temel sunmaktadır.

Projede FLEURS'un tüm split'leri birleştirilerek yaklaşık 2.000 eşsiz dosya kullanılmıştır. Veri kümesinin toplam örnek sayısının diğer kaynaklara kıyasla sınırlı kalması nedeniyle tekrarlı örnekleme yerine CommonVoice'tan daha fazla örnek alınması tercih edilmiştir. Bu karar, veri çeşitliliğini koruyarak overfite azaltmayı hedeflemiştir.

CommonVoice 17 TR

CommonVoice, Mozilla Vakfı tarafından yürütülen ve gönüllü katılımcıların katkısıyla oluşturulan açık kaynak bir konuşma veri kümesidir. 17. sürümünün Türkçe bölümü, farklı yaş gruplarından, aksanlardan ve ses kalitesi koşullarından gelen 46.000'i aşkın doğrulanmış ses kaydını içermektedir. Bu çeşitlilik, modelin gerçek hayatta karşılaşacağı farklı konuşmacı profillerine karşı genelleme yapabilmesi açısından kritik öneme sahiptir.

Projede train split'inden 12.000 örnek rastgele örneklenmiş ve eğitim veri kümesine dahil edilmiştir. CommonVoice kayıtları gönüllü katılımcılar tarafından ev veya ofis gibi farklı ortamlarda alındığından hafif arka plan gürültüsü içerebilmektedir. Tüm dosyalar 16 kHz örnekleme hızına dönüştürülmüş, mono kanala indirgenmiş ve tepe normalizasyonu uygulanmıştır.

Microsoft DNS Challenge 4 Gürültü Veri Kümesi

Microsoft'un Deep Noise Suppression Challenge kapsamında yayımladığı bu veri kümesi, gerçek ortam koşullarını temsil eden çeşitli gürültü tiplerini içermektedir. Ofis ortamı, araç içi, sokak, kalabalık mekân, müzik ve çeşitli elektronik cihaz gürültüleri gibi günlük hayatta sıkça karşılaşılan sesler bu veri kümesinde yer almaktadır.

Projede DNS-4 veri kümesinin gürültü bölümünden 659 dosyalık bir alt küme kullanılmıştır. Bu gürültü dosyaları temiz konuşma kayıtlarıyla altı farklı sinyal-gürültü oranında (-5 dB, 0 dB, +5 dB, +10 dB, +15 dB, +20 dB) on-the-fly olarak karıştırılmıştır. Eğitim sırasında anlık olarak augmentation yaklaşımı, sabit gürültülü-temiz çiftleri önceden oluşturup diske yazmak yerine her eğitim adımında farklı kombinasyonlar üretmektedir. Bu sayede aynı temiz ses dosyası her epoch'ta farklı bir gürültü ve SNR değeriyle modele sunulmuş, veri çeşitliliği artırılarak modelin farklı gürültü koşullarına karşı genelleme yapabilmesi desteklenmiştir.

Veri Hazırlama Süreci

Tüm ses dosyaları eğitim öncesinde aşağıdaki standart ön işleme adımlarından geçirilmiştir. Tüm kayıtlar 16 kHz örnekleme hızına dönüştürülmüştür çünkü kullanılan model mimarilerinin tamamı bu örnekleme hızı için tasarlanmıştır. Stereo veya çok kanallı kayıtlar ortalamaları alınarak mono kanala indirgenmiştir. Her ses dosyasının tepe genliği 0.9 değerine normalize edilerek model girişindeki ölçek tutarlılığı sağlanmıştır. 1 saniyeden kısa ve 20 saniyeden uzun kayıtlar filtrelenmiştir; çok kısa kayıtlar segment kırpma için yetersiz kalmakta, çok uzun kayıtlar ise bellek sorunlarına yol açabilmektedir. Son olarak verinin yüzde doksanı eğitim, yüzde onu doğrulama için ayrılmış ve bu bölünme tüm modellerde aynı biçimde uygulanarak adil karşılaştırma koşulları sağlanmıştır.

2.3.6. Geliştirilen Modeller ve Karşılaştırmalı Sonuçları

Bu proje kapsamında beş farklı model mimarisi Türkçe konuşma verisi üzerinde eğitilmiş ve değerlendirilmiştir. Modeller birbiriyle adil karşılaştırma yapılabilmesi amacıyla aynı veri kümesi, aynı gürültü kaynağı, aynı SNR aralığı ve aynı değerlendirme seti kullanılarak test edilmiştir. Her modelin eğitim yaklaşımı, mimari özellikleri ve elde ettiği sonuçlar aşağıda ayrıntılı biçimde açıklanmıştır.

FullSubNet+

FullSubNet+ İngilizce konuşma verisiyle ön eğitimi tamamlanmış pretrained ağırlıklardan başlatılarak Türkçe veri üzerinde ince ayar yapılmıştır. 18 epoch eğitim sonucunda val loss en düşük değere ulaşmış ve erken durdurma ile eğitim sonlandırılmıştır. Model, cIRM maskesi üretilip bu maskeyi gürültülü spektrograma uygulayarak temizlenmiş sesi elde etmektedir. PESQ skorunda 1.572'den 2.559'a ulaşarak grubun pretrained modelleri arasında dengeli bir performans sergilemiştir. SI-SDR'da +9.71 dB iyileştirme sağlamıştır.

Veri seti / dil: Google FLEURS tr_tr + CommonVoice 17 TR, Türkçe konuşma, 14.000 temiz ses dosyası

Gürültü kaynağı: Microsoft DNS Challenge 4, 659 dosya, 6 farklı SNR seviyesi (-5 dB ile +20 dB arası), on-the-fly augmentation

Train / Val örnek sayısı: ~12.535 train / ~1.392 validation (temiz dosya bazında %90/%10 bölünmesi; on-the-fly augmentation ile her epoch farklı gürültülü-temiz çifti üretilmektedir)

Segment uzunluğu: 3.072 saniye (49.152 örnek @ 16 kHz)

Batch / Epoch: A100 40GB üzerinde batch=32; 18 epoch eğitim tamamlanmış, en iyi checkpoint epoch 12'de alınmıştır

Model / omurga: FullSubNet+ (Fullband-Subband LSTM hibrit); ~8.6 milyon parametre

Ön eğitim durumu: DNS Challenge İngilizce verisiyle ön eğitimi tamamlanmış pretrained ağırlıklardan başlatılmıştır; tüm katmanlar fine-tuning sürecinde güncellenmiştir

LR / optimizasyon: Adam optimizer, lr=1e-4, betas=(0.9, 0.999); ReduceLROnPlateau scheduler, 3 epoch iyileşme olmazsa LR yarıya düşürülmüş, minimum LR=1e-6


Loss / eğitim mantığı: L1 kaybı + Çok Ölçekli STFT kaybı + SI-SDR kaybı kombinasyonu (ağırlıklar sırasıyla 0.45 / 0.45 / 0.10); L1 genel ses kalitesini, STFT frekans alanı detaylarını, SI-SDR ise sinyal-gürültü oranını optimize etmektedir

Değerlendirme stratejisi: Her epoch sonunda val loss izlenmiş; 6 epoch boyunca iyileşme olmazsa early stopping tetiklenmiştir. En iyi checkpoint val loss bazında seçilmiş, 200 örneklik validation alt kümesinde SI-SDR, PESQ ve STOI metrikleri hesaplanmıştır

Mixed precision: A100 ortamında AMP (Automatic Mixed Precision) aktif; gradient clipping (max norm=1.0) ile eğitim kararlılığı sağlanmıştır

Sonuçlar: SI-SDR 7.05 dB → 16.76 dB (+9.71 dB), PESQ 1.572 → 2.559 (+0.987), STOI 0.837 → 0.924 (+0.087)

Aşağıda FullSubNet+ için Loss ve SI-SDR iyileşmesi grafikleri verilmiştir:



Şekil 1.1

MossFormerGAN_SE_16K

MossFormerGAN, Transformer tabanlı MossFormer2 mimarisi üzerine inşa edilmiş ve GAN eğitimiyle desteklenmiştir. Pretrained ağırlıklardan başlatılarak 33 epoch eğitim yapılmıştır. GAN bileşeninin algısal kaliteye katkısı değerlendirme sonuçlarında açıkça görülmektedir;

PESQ skorunda 2.633 ile grubun en yüksek değerine ulaşmıştır. STOI açısından da 0.934 ile en iyi sonucu elde eden model olmuştur. Kulak testi değerlendirmesinde de en temiz ve doğal sesi üreten model olarak öne çıkmıştır. Yaklaşık 25 milyon parametresiyle grubun en büyük modelidir.

Veri seti / dil: Google FLEURS tr_tr + CommonVoice 17 TR, Türkçe konuşma, 14.000 temiz ses dosyası

Gürültü kaynağı: Microsoft DNS Challenge 4, 659 dosya, 6 farklı SNR seviyesi (-5 dB ile +20 dB arası), on-the-fly augmentation

Train / Val örnek sayısı: ~12.535 train / ~1.392 validation (temiz dosya bazında %90/%10 bölünmesi)

Segment uzunluğu: 1.275 saniye (20.400 örnek @ 16 kHz; modelin pretrained ağırlıklarının eğitildiği sabit pencere boyutu)

Batch / Epoch: A100 40GB üzerinde batch=4, gradient accumulation=4 (efektif batch=16); 33 epoch eğitim tamamlanmış, en iyi checkpoint epoch 26'da alınmıştır

Model / omurga: MossFormerGAN_SE_16K (MossFormer2 Transformer + GAN); generator ~3.1M, discriminator ~8.1M, toplam ~25M parametre

Ön eğitim durumu: alibabasglab/MossFormerGAN_SE_16K HuggingFace deposundan sağlanan pretrained ağırlıklardan başlatılmıştır; generator ağırlıkları missing=0, unexpected=0 ile eksiksiz yüklenmiştir


LR / optimizasyon: Adam optimizer, lr=1e-4, betas=(0.9, 0.999); ReduceLROnPlateau scheduler, 3 epoch iyileşme olmazsa LR yarıya düşürülmüş, minimum LR=1e-6

Loss / eğitim mantığı: L1 kaybı + Çok Ölçekli STFT kaybı kombinasyonu; spektral alan üzerinde hesaplanmıştır. GAN bileşeni inference kalitesini artırmak için mimarisel olarak mevcuttur ancak fine-tuning aşamasında yalnızca generator optimize edilmiştir

Değerlendirme stratejisi: Her epoch sonunda val loss izlenmiş; 6 epoch boyunca iyileşme olmazsa early stopping tetiklenmiştir. En iyi checkpoint val loss bazında seçilmiş, 200 örneklik validation alt kümesinde SI-SDR, PESQ ve STOI metrikleri hesaplanmıştır

Mixed precision: A100 ortamında AMP devre dışı bırakılmıştır; kompleks tensör işlemleriyle uyumsuzluk nedeniyle float32 ile eğitim yapılmıştır

Sonuçlar: SI-SDR 8.33 dB $\rightarrow$ 17.85 dB (+9.08 dB), PESQ 1.572 $\rightarrow$ 2.633 (+1.227), STOI 0.863 $\rightarrow$ 0.934 (+0.082)



Şekil 2.1

FRCRN

FRCRN sıfırdan eğitilmiştir. Veri hazırlama aşamasında temiz ses dosyaları doğal uzunluklarıyla diske kaydedilmiş, kırpma ve sıfır dolgusu işlemleri yalnızca eğitim sırasında Veri setinin örnekleme adımında gerçekleştirilmiştir. Bu yaklaşım modelin farklı uzunluktaki ses yapılarını görmesine olanak tanıyarak genelleme kapasitesini artırmıştır. Learning rate $1e-4$ olarak belirlenmiş ve 26 epoch eğitim tamamlanmıştır. 10.3 milyon parametresiyle grubun orta büyüklükteki modelidir.

Değerlendirme sonuçlarında SI-SDR 7.85 dB olan gürültülü girişi 18.51 dB'ye taşıyarak +10.66 dB iyileştirme sağlamıştır. PESQ skoru 1.572'den 2.470'e yükselmiş; bu değer 2.5 eşiğinin hemen altında kalmakla birlikte sıfırdan eğitilen modeller arasında rekabetçi bir sonuçtur. STOI açısından ise 0.863'ten 0.926'ya ulaşarak konuşma anlaşılabilirliğinde belirgin bir iyileşme sağlamış ve bu metrikte pretrained modeller dahil grubun ikinci en iyi değerini elde etmiştir.

Veri seti / dil: Google FLEURS tr_tr + CommonVoice 17 TR, Türkçe konuşma, 14.000 temiz ses dosyası

Gürültü kaynağı: Microsoft DNS Challenge 4, 659 dosya, 6 farklı SNR seviyesi (-5 dB ile +20 dB arası), on-the-fly augmentation

Train / Val örnek sayısı: ~12.535 train / ~1.392 validation (temiz dosya bazında %90/%10 bölünmesi)

Segment uzunluğu: 4.0 saniye (64.000 örnek @ 16 kHz)

Batch / Epoch: A100 40GB üzerinde batch=8; 26 epoch eğitim tamamlanmış, en iyi checkpoint epoch 26'da alınmıştır

Model / omurga: FRCRN (Frequency Recurrent Complex-valued U-Net); ~10.3 milyon parametre

Ön eğitim durumu: Pretrained ağırlık kullanılmamıştır; model sıfırdan eğitilmiştir. Tüm ağırlıklar rastgele başlatılmış ve yalnızca Türkçe veri üzerinde öğrenilmiştir


LR / optimizasyon: Adam optimizer, lr=1e-4, betas=(0.9, 0.999); ReduceLROnPlateau scheduler, 3 epoch iyileşme olmazsa LR yarıya düşürülmüş, minimum LR=1e-6; gradient clipping max norm=5.0

Loss / eğitim mantığı: L1 kaybı + Çok Ölçekli STFT kaybı + SI-SDR kaybı kombinasyonu (ağırlıklar sırasıyla 0.45 / 0.45 / 0.10); kompleks spektrogram çıktısı üzerinde hesaplanmıştır

Değerlendirme stratejisi: Her epoch sonunda val loss izlenmiş; 6 epoch boyunca iyileşme olmazsa early stopping tetiklenmiştir. En iyi checkpoint val loss bazında seçilmiş, 200 örneklik validation alt kümesinde SI-SDR, PESQ ve STOI metrikleri hesaplanmıştır

Mixed precision: A100 ortamında AMP aktif; gradient clipping ile birlikte eğitim kararlılığı sağlanmıştır

Sonuçlar: SI-SDR 7.85 dB → 18.51 dB (+10.66 dB), PESQ 1.572 → 2.470 (+0.898), STOI 0.872 → 0.926 (+0.053)



Şekil 3.1

GTCRN

GTCRN sıfırdan eğitilmiş olup yaklaşık 6.9 milyon parametresiyle grubun en hafif modelidir. 30 epoch eğitim tamamlanmış ve SI-SDR delta açısından +10.74 dB ile en yüksek değere ulaşmıştır. Bu sonuç kısmen modelin loss fonksiyonunun SI-SDR optimizasyonuna daha ağırlık vermesinden kaynaklanmaktadır. Buna karşın pretrained ağırlık kullanmadan sıfırdan eğitilmiş olmasına ve diğer modellere kıyasla belirgin biçimde daha az parametreye sahip olmasına rağmen FullSubNet+'a yakın PESQ ve STOI değerleri elde etmesi dikkat çekici bir bulgudur.

Veri seti / dil: Google FLEURS tr_tr + CommonVoice 17 TR, Türkçe konuşma, 14.000 temiz ses dosyası

Gürültü kaynağı: Microsoft DNS Challenge 4, 659 dosya, 6 farklı SNR seviyesi (-5 dB ile +20 dB arası), on-the-fly augmentation

Train / Val örnek sayısı: ~12.535 train / ~1.392 validation (temiz dosya bazında %90/%10 bölünmesi)

Segment uzunluğu: 3.072 saniye (49.152 örnek @ 16 kHz)

Batch / Epoch: A100 40GB üzerinde batch=32; 30 epoch eğitim tamamlanmış, erken durdurma tetiklenmemiş ve tüm epochlar tamamlanmıştır

Model / omurga: GTCRN (Gated Temporal Convolutional Recurrent Network); ~6.9 milyon parametre; n_fft=512, hop_length=256

Ön eğitim durumu: Pretrained ağırlık kullanılmamıştır; model sıfırdan eğitilmiştir. Tüm ağırlıklar rastgele başlatılmış ve yalnızca Türkçe veri üzerinde öğrenilmiştir


LR / optimizasyon: Adam optimizer, lr=1e-4, betas=(0.9, 0.999); ReduceLROnPlateau scheduler, 3 epoch iyileşme olmazsa LR yarıya düşürülmüş, minimum LR=1e-6; gradient clipping max norm=5.0

Loss / eğitim mantığı: L1 kaybı + Çok Ölçekli STFT kaybı + SI-SDR kaybı kombinasyonu (ağırlıklar sırasıyla 0.45 / 0.45 / 0.10); zaman alanı ve spektral alan üzerinde birlikte optimize edilmiştir

Değerlendirme stratejisi: Her epoch sonunda val loss izlenmiş; 6 epoch boyunca iyileşme olmazsa early stopping tetiklenmiştir. En iyi checkpoint val loss bazında seçilmiş, 200 örneklik validation alt kümesinde SI-SDR, PESQ ve STOI metrikleri hesaplanmıştır

Mixed precision: A100 ortamında AMP aktif; gradient clipping ile birlikte eğitim kararlılığı sağlanmıştır

Sonuçlar: SI-SDR 7.83 dB $\rightarrow$ 18.56 dB (+10.74 dB), PESQ 1.545 $\rightarrow$ 2.489 (+0.944), STOI 0.863 $\rightarrow$ 0.921 (+0.059)



Şekil 4.1


SGMSE+

SGMSE+, skor tabanlı üretici modelleme (score-based generative modeling) yaklaşımından ilham alınarak geliştirilen, difüzyon sürecini ses iyileştirme görevine uyarlayan bir model mimarisidir. Geleneksel maskele-ve-uygula yaklaşımı yerine, gürültülü sesi iteratif bir geri diffusion süreciyle temiz sese yaklaştırmayı hedefler. Projede bu mimari sıfırdan eğitilmiştir; zaman gömme katmanları ve U-Net tarzı kodlayıcı-çözücü yapısı, hem zamansal hem de spektral bağımlılıkları öğrenmek için birlikte kullanılmaktadır.

40 epoch boyunca tutarlı biçimde öğrenme devam etmiş, erken durdurma tetiklenmemiş ve val loss her epoch periyodunda iyileşme eğilimini sürdürmüştür. En iyi checkpoint epoch 37'de elde edilmiştir. 7.5 milyon parametresiyle grubun daha hafif modellerinden biridir. SI-SDR metriğinde grup içinde en yüksek delta değerine ulaşmış; PESQ açısından ise diğer modellerin gerisinde kalmıştır. Bu durum difüzyon tabanlı yaklaşımın matematiksel sinyal kalitesini güçlü biçimde optimize ettiğini, ancak algısal kalite açısından yeterince olgunlaşabilmesi için daha uzun eğitim veya daha büyük veri gerektirebileceğini göstermektedir.

- **Veri seti / dil:** Google FLEURS tr_tr + CommonVoice 17 TR, Türkçe konuşma, 14.000 temiz ses dosyası

- **Gürültü kaynağı:** Microsoft DNS Challenge 4, 659 dosya, 6 farklı SNR seviyesi (-5 dB ile +20 dB arası), on-the-fly augmentation
- **Train / Val örnek sayısı:** ~12.600 train / ~1.400 validation (temiz dosya bazında %90/%10 bölünmesi)
- **Segment uzunluğu:** 4.0 saniye (64.000 örnek @ 16 kHz)
- **Batch / Epoch:** A100 40GB üzerinde batch=8, gradient accumulation=2 (efektif batch=16); 40 epoch eğitim tamamlanmış, en iyi checkpoint epoch 37'de alınmıştır
- **Model / omurga:** SGMSE+ benzeri skor tabanlı spektrogram iyileştirme mimarisi; zaman gömme katmanları + U-Net tarzı kodlayıcı-çözücü; ~7.5 milyon parametre
- **Ön eğitim durumu:** Pretrained ağırlık kullanılmamıştır; model sıfırdan eğitilmiştir
- **LR / optimizasyon:** Adam optimizer, lr=5e-5; ReduceLROnPlateau scheduler, 3 epoch iyileşme olmazsa LR yarıya düşürülmüş, minimum LR=1e-6; gradient clipping uygulanmıştır
- **Loss / eğitim mantığı:** L1 kaybı + Çok Ölçekli STFT kaybı + SI-SDR kaybı + difüzyon tutarlılık kaybı kombinasyonu; difüzyon bileşeni modelin iteratif geri diffusion sürecini düzenlemektedir
- **Değerlendirme stratejisi:** Her epoch sonunda val loss izlenmiş; en iyi checkpoint val loss bazında seçilmiş, 200 örneklik validation alt kümesinde SI-SDR, PESQ ve STOI metrikleri hesaplanmıştır
- **Mixed precision:** A100 ortamında AMP aktif; gradient accumulation ile eğitim kararlılığı sağlanmıştır
- **Sonuçlar:** SI-SDR 7.50 dB → 18.48 dB (+10.98 dB), PESQ 1.598 → 2.288 (+0.690), STOI 0.866 → 0.907 (+0.041)



Karşılaştırmalı Sonuçlar

Aşağıdaki tabloda tüm modellerin eğitim koşulları ve değerlendirme metrikleri bir arada sunulmaktadır.

	GTCRN	FullSubNet +	FRCRN	MossFormerG AN	SGMSE+
Mimari	CNN + STFT	LSTM + cIRM	Kompleks U-Net	Transformer + GAN	Difüzyon+U-Net
Parametre	6.9M	8.6M	10.3M	~25M	7.5M
Pretrained	Yok	Var	Yok	Var	Yok
Epoch	30	18	26	33	37
SI-SDR (dB)	18.56	16.76	18.51	17.85	18.48
SI-SDR Δ	+10.74	+9.71	+10.66	+9.08	+10.98
PESQ	2.489	2.559	2.470	2.633	2.288
STOI	0.921	0.924	0.926	0.934	0.907

Sonuçlar değerlendirildiğinde birkaç önemli bulgu öne çıkmaktadır.

Algısal kalite açısından MossFormerGAN belirgin biçimde öne çıkmaktadır. PESQ ve STOI metriklerinde grubun en yüksek değerlerini elde etmiş, kulak testi değerlendirmesinde de en doğal ve temiz sesi ürettiği gözlemlenmiştir. Bu sonuç GAN eğitiminin Algısal kaliteye somut katkısını doğrulamaktadır.

SI-SDR delta açısından en yüksek iyileştirme SGMSE+ modelinde gözlemlenmiştir. GTCRN ve FRCRN ise SGMSE+'e çok yakın değerler üreterek sıfırdan eğitilen modeller arasında güçlü sonuçlar vermiştir. Ancak SGMSE+'in PESQ değerinin diğer modellere göre düşük kalması, yüksek SI-SDR iyileştirmesinin her zaman daha yüksek algısal kalite anlamına gelmediğini göstermektedir.

Parametre verimliliği açısından en dikkat çekici bulgu GTCRN'e aittir. Yalnızca 6.9 milyon parametreyle ve sıfırdan eğitilmiş olmasına karşın PESQ ve STOI değerlerinde 8.6 milyon parametrelili ve pretrained ağırlıklarla başlatılan FullSubNet+'a yakın sonuçlar elde etmiştir. Bu

durum mimari tasarım ve loss fonksiyonu seçiminin parametre sayısından daha belirleyici olabileceğini göstermektedir.

2.4. Genel Değerlendirme ve Nihai Tercihler

Sonuçlar birlikte değerlendirildiğinde modellerin farklı güçlü yönleriyle öne çıktığı görülmektedir. Hiçbir model tüm metriklerde eş zamanlı olarak birinci sıraya yerleşmemiş; her mimari bazı boyutlarda diğerlerinden ayrılmıştır. Bu durum, gürültü giderme görevinde tek bir "en iyi model" yerine kullanım senaryosuna göre farklı tercihlerin yapılması gerektiğini ortaya koymaktadır.

Algısal kalite öncelikli senaryolarda, yani kullanıcının sesi bizzat dinleyeceği durumlarda MossFormerGAN en güçlü aday olarak öne çıkmaktadır. PESQ 2.633 ve STOI 0.934 ile grubun tüm modellerini geride bırakmış; kulak testi değerlendirmesinde de en doğal ve temiz sesi üreten model olarak öne çıkmıştır. GAN bileşeninin algısal kaliteye olan katkısı bu sonuçlarla somut biçimde doğrulanmıştır. Yaklaşık 25 milyon parametresiyle grubun en büyük modeli olmasına karşın A100 GPU üzerinde makul bir eğitim süresiyle hedeflenen performansa ulaşmıştır.

Sinyal gürültü oranı iyileştirmesi öncelikli senaryolarda, yani otomatik konuşma tanıma veya transkripsiyon gibi makinenin sesi işleyeceği durumlarda GTCRN ve FRCRN öne çıkmaktadır. SI-SDR delta açısından FRCRN +10.66 dB ve GTCRN +10.74 dB ile pretrained modelleri geride bırakmıştır. Bu iki model sıfırdan eğitilmiş ve loss fonksiyonlarında SI-SDR bileşeni etkin biçimde kullanılmıştır.

Parametre verimliliği ve kompaktlık açısından GTCRN dikkat çekici bir konumda yer almaktadır. Yalnızca 6.9 milyon parametreyle ve sıfırdan eğitilmiş olmasına karşın 8.6 milyon parametrelili ve pretrained ağırlıklarla başlatılan FullSubNet+'a PESQ ve STOI metriklerinde yakın sonuçlar üretmiştir. Bu bulgu, doğru mimari tasarım ve loss fonksiyonu seçiminin parametre sayısından daha belirleyici olabileceğini göstermektedir.

Özetle:

- **En yüksek algısal kalite (PESQ, STOI):** MossFormerGAN — kullanıcıya yönelik uygulamalar, podcast, sesli içerik üretimi
- **En yüksek SI-SDR iyileştirmesi:** GTCRN ve SGMSE+ — otomatik konuşma tanıma, transkripsiyon, arşiv uygulamaları

- **En iyi parametre-performans dengesi:** GTCRN — kaynak kısıtlı ortamlar, edge deployment
- **En dengeli genel performans:** FullSubNet+ — pretrained avantajıyla tüm metriklerde tutarlı sonuçlar

Bu doğrultuda nihai sistemde kalite önceliği varsa MossFormerGAN varsayılan model olarak konumlandırılmalıdır. Daha hafif ve taşınabilir bir yapı isteniyorsa GTCRN güçlü bir alternatif olarak değerlendirilebilir. Otomatik işleme odaklı bir sistem tasarımında ise FRCRN ve GTCRN birlikte değerlendirilebilir.

3. TASARIM

3.1. Sistem Mimarisi ve Bileşenleri

Proje, modüler bir mimari yaklaşımı temel alınarak tasarlanmıştır. Ses verisinin işlenmesi, gürültü augmentation, model eğitimi, değerlendirme ve dağıtım aşamaları birbirinden ayrılmış bileşenler olarak ele alınmıştır. Bu yapı sayesinde her bileşen bağımsız olarak geliştirilebilir, test edilebilir ve farklı model veya yöntemlerle değiştirilebilir.

Sistemin genel amacı, kullanıcıdan alınan gürültülü Türkçe ses sinyalini işleyerek temiz konuşmayı geri kazandırmaktır. Bu amaçla ses sinyali önce ön işleme adımlarından geçirilir, ardından derin öğrenme modellerine beslenir ve model çıktısı temizlenmiş ses olarak kullanıcıya sunulur.

Sistem temel olarak üç ana katmandan oluşur.

3.1.1. Kullanıcı Arayüzü

Kullanıcı arayüzü, kullanıcının sistemle doğrudan etkileşime geçtiği katmandır. React ile geliştirilen web tabanlı ön yüz, kullanıcının gürültülü ses dosyasını sisteme yüklemesini, işlem sürecini başlatmasını ve temizlenmiş ses çıktısını dinleyip indirmesini sağlar. Arayüz, işlem mantığından bağımsız olarak tasarlanmıştır; model çalıştırma ve ses işleme gibi işlemler doğrudan arayüz içinde değil, arka uç servis katmanı üzerinden gerçekleştirilir.

3.1.2. Ses İşleme ve İş Akışı Katmanı

Bu katman, kullanıcıdan alınan ses dosyasının sistem içinde hangi adımlardan geçeceğini yöneten ana mantık katmanıdır. FastAPI ile geliştirilen arka uç servisi bu katmanı oluşturmaktadır.

İlk aşamada kullanıcıdan alınan ses dosyası sisteme alınır ve modelin beklediği giriş formatına uygun hale getirilir. Bu aşamada dosya formatının kontrolü, örnekleme hızının 16 kHz'e dönüştürülmesi, stereo kanalın mono kanala indirgenmesi ve tepe normalizasyonu uygulanması işlemleri gerçekleştirilir. Giriş dosyası WAV, MP3 veya FLAC formatında olabilir.

İkinci aşamada gürültü giderme modeli çalıştırılır. Model, ses sinyalinin gürültüyü ayırarak temizlenmiş sesi üretir. Bu çıktı doğrudan kullanıcıya verilmez; önce post-processing adımlarından geçirilir. Peak normalizasyon uygulanarak çıktı genliği güvenli bir seviyeye getirilir ve ardından kullanıcıya sunulmak üzere WAV formatına dönüştürülür.

Bu katmanın önemli görevlerinden biri, farklı model mimarilerine yönelik uyumlu bir arayüz sunmaktır. FullSubNet+, MossFormerGAN, FRCRN ve GTCRN gibi farklı mimariler birbirinden farklı giriş formatları beklemektedir. Zaman alanında çalışan modeller ham dalga biçimi alırken frekans alanında çalışan modeller STFT spektrogramı beklemektedir. Bu dönüşümler iş akışı katmanında şeffaf biçimde gerçekleştirilir.

3.1.3. Model Erişim Katmanı

Model Erişim katmanı, sistemin en kritik bileşenidir. Bu katmanın temel görevi gürültülü ses sinyalinin temiz konuşmayı geri kazandırmaktır. Proje kapsamında bu amaçla beş farklı derin öğrenme modeli geliştirilmiş ve karşılaştırılmıştır.

Bu katmanda modeller iki farklı yaklaşımla çalışmaktadır. Frekans alanı tabanlı modeller (FullSubNet+, MossFormerGAN, FRCRN, SGMSE+) gürültülü sesi önce STFT ile spektrograma dönüştürür, spektrogram üzerinde gürültüyü maskeleyerek temizlenmiş spektrogramı elde eder ve ardından iSTFT ile zaman alanına geri dönüştürür. Zaman alanı tabanlı modeller ise ham dalga biçimi üzerinde doğrudan çalışarak ara dönüşüm adımına ihtiyaç duymadan temizlenmiş sesi üretir.

Model Erişim katmanı modüler olarak tasarlanmıştır. Bu sayede FullSubNet+, MossFormerGAN, FRCRN, GTCRN ve SGMSE+ modellerinden herhangi biri aynı sistem içinde değiştirilebilir biçimde kullanılabilir. Böyle bir yapı, model geliştirme süreci devam ederken sistem mimarisinin bozulmadan korunmasını sağlar.

3.1.4. Girdi Hazırlama ve Modele Besleme

Sisteme giren ses dosyaları modelin beklediği giriş formatına uygun hale getirilmeden doğrudan modele verilmemektedir. İlk aşamada kullanıcıdan alınan dosya okunur ve format kontrolleri yapılır. Daha sonra ses, 16 kHz örnekleme hızına dönüştürülür; mono kanala indirgenir ve tepe normalizasyonu uygulanır. Uzun ses dosyaları modelin beklediği segment uzunluklarına bölünür; kısa dosyalar ise sıfır dolgusuyla tamamlanır.

Modelin eğitim ve çıkarım sürecinde tutarlı sonuçlar üretebilmesi için tüm giriş sesleri aynı ön işleme adımlarından geçirilir. Frekans alanı tabanlı modeller için ek olarak STFT dönüşümü uygulanır. STFT parametreleri (FFT uzunluğu, pencere uzunluğu, adım büyüklüğü) her modelin pretrained ağırlıklarının eğitildiği konfigürasyona uygun biçimde seçilir.

3.1.5. Çıktı Üretimi ve Post-Processing

Modelin ham çıktısı doğrudan kullanıcıya sunulmaz. İlk aşamada model çıktısı orijinal ses uzunluğuyla hizalanır; segment bazlı işlem yapılmışsa segmentler birleştirilerek sürekli bir ses dosyası oluşturulur. Ardından çıktı sinyaline tepe normalizasyonu uygulanarak olası sayısal taşmalar önlenir ve kullanıcıya sunulabilir bir genlik seviyesi sağlanır.

3.2. Ekranlar

3.2.1. Ses Temizleme Ekranı

Ses temizleme ekranı, kullanıcının gürültülü bir konuşma kaydını sisteme yükleyip seçtiği yapay zeka modeliyle işlemlerini ve ardından orijinal ile temizlenmiş sesi farklı görsel analiz modlarıyla karşılaştırmasını sağlayan ana kullanıcı arayüzüdür.

Temel İş Akışı

Kullanıcı önce sistemde kayıtlı modellerden birini seçer. Model listesi arka uç servisinden dinamik olarak alınır ve açılır menü biçiminde ekrana yansıtılır. Ardından ses dosyası yüklenir veya mikrofon aracılığıyla doğrudan kayıt alınır. Ses hazır olduktan sonra temizleme işlemi başlatılır. Sistem dosyayı arka uca ileterek modeli çalıştırır ve işlem tamamlandığında temizlenmiş ses ekranda gösterilir.

Ses Girişi

Ekran iki farklı ses alma yöntemi sunar. Kullanıcı bilgisayarından dosya seçebilir ya da dosyayı sürükleyip bırakabilir. Desteklenen formatlar WAV, MP3, OGG, FLAC ve M4A olarak belirlenmiş olup maksimum dosya boyutu 100 MB ile sınırlandırılmıştır. Geçersiz format veya boyut sınırını aşan dosya seçildiğinde kullanıcıya bilgilendirici bir hata mesajı gösterilir. İkinci yöntem olarak mikrofon ile doğrudan kayıt alınabilir. Tarayıcıdan mikrofon izni alındıktan sonra kayıt başlar; tekrar basıldığında kayıt sonlandırılır ve sistem bu kaydı işleme hazır hale getirir.

Model Seçimi

Ses temizleme işlemi başlatılmadan önce bir model seçilmesi zorunludur. Ekran, sistemde aktif olan modelleri listeler. Proje kapsamında geliştirilen FRCRN, GTCRN, FullSubNet+ ve MossFormerGAN modelleri bu liste üzerinden seçilebilir. Model seçilmeden işlem başlatılmaya çalışıldığında sistem kullanıcıyı uyarır.

İşlem Durumu Takibi

Temizleme işlemi başlatıldığında ekran süreci adım adım gösterir. Dosya yükleme, ön işleme, model çalıştırma ve çıktı hazırlama olmak üzere dört aşamadan oluşan bu süreçte her adımın tamamlanma durumu kullanıcıya iletilir. Dosya yükleme aşamasında yüzde bilgisi anlık olarak gösterilir. İşlem devam ederken kontroller pasif hale getirilerek aynı dosya için birden fazla işlem başlatılması engellenir. İşlem başarıyla tamamlandığında temizlenmiş ses ekrana yüklenir; hata veya zaman aşımı durumunda ise kullanıcıya açıklayıcı bir uyarı mesajı sunulur.

Dalga Formu Görünümü

İşlem tamamlandıktan sonra varsayılan olarak dalga formu görünümü açılır. Bu görünümde orijinal ses ve temizlenmiş ses ayrı paneller halinde sunulur. Her panelde sesin zaman çizgisi ile oynatma, duraklatma ve başa dönme kontrolleri yer alır. Temizlenmiş ses için indirme seçeneği de sunulmakta olup kullanıcı çıktıyı WAV formatında bilgisayarına kaydedebilir. Ayrıca dalga formu örtüşme görünümü açıldığında orijinal ve temizlenmiş ses aynı grafik üzerinde karşılaştırılarak ikisi arasındaki fark daha kolay gözlemlenebilir.


Spektrogram Görünümü

Spektrogram sekmesi sesin frekans-zaman analizini görsel olarak sunar. Solda orijinal ses, sağda temizlenmiş ses spektrogramı yer alır. Her panelde oynatma kontrolü, süre göstergesi ve

fareyle üzerine gelindiğinde zaman ile frekans bilgisini anlık olarak gösteren etkileşimli bilgi alanı bulunur. Konuşma bandı özelliği etkinleştirildiğinde spektrogram yalnızca insan konuşması açısından kritik olan yaklaşık 300 Hz ile 4 kHz aralığına odaklanır; bu sayede konuşma bileşenlerinin gürültüden ne ölçüde ayrıştırıldığı daha ayrıntılı biçimde incelenebilir.

3D Görünüm

3D görünüm sekmesi sesin enerji dağılımını üç boyutlu bir yüzey haritası olarak sunar. Kullanıcı bu sahneyi fareyle döndürebilir, yakınlaştırabilir ve kaydırabilir. Üç farklı mod desteklenir: orijinal enerji, temizlenmiş enerji ve fark görünümü. Temizleme işlemi tamamlanmadan önce yalnızca orijinal enerji yüzeyi anlamlıdır; işlem tamamlandıktan sonra temizlenmiş enerji ve fark modları da aktif hale gelir. Fark modu, iki sinyal arasındaki enerji farklılıklarını üç boyutlu olarak görselleştirerek modelin hangi frekans ve zaman bölgelerinde ne miktarda gürültü bastırdığını sezgisel biçimde ortaya koymaktadır.



Şekil 3.1. Ses Temizle Sayfası ve Dalga Formu Görünümü

Kullanıcı önce karşılaştırılacak ses dosyasını yükler veya mikrofon aracılığıyla kayıt alır. Ardından sol ve sağ panel için iki farklı model seçer. Karşılaştırma başlatıldığında sistem aynı orijinal ses kaydını seçilen iki modelle ayrı ayrı işler. İşlem tamamlandığında sol panelde birinci modelin, sağ panelde ikinci modelin temizlenmiş ses çıktısı gösterilir.

Ses Girişi

Bu ekran ses temizleme ekranıyla aynı ses yükleme bileşenini kullanır. Kullanıcı dosyayı sürükleyip bırakabilir, dosya seçim menüsünden seçebilir veya mikrofon ile doğrudan kayıt alabilir. Desteklenen formatlar WAV, MP3, OGG, FLAC ve M4A olup maksimum dosya boyutu 100 MB ile sınırlandırılmıştır. Ses dosyası seçilmeden karşılaştırma başlatılmak istendiğinde sistem kullanıcıyı bilgilendirir.

İki Model Seçimi

Ekranda iki ayrı model seçici bulunur. Sol seçici birinci çıktıyı, sağ seçici ikinci çıktıyı temsil eder. Model listesi arka uç servisinden dinamik olarak alınır. Varsayılan olarak ilk model sol panele, varsa ikinci model sağ panele atanır. Kullanıcı her iki tarafta aynı modeli seçebilir; ancak ekranın asıl kullanım amacı farklı iki modelin performansının karşılaştırılmasıdır. Model seçimi değiştirildiğinde ilgili panelin önceki sonucu otomatik olarak temizlenir; bu sayede eski model çıktısıyla yeni seçim arasında karışıklık oluşması engellenir.

Karşılaştırma İşlemi

Karşılaştırma başlatıldığında sistem önce ses dosyasını arka uca iletir. Aynı ses daha önce yüklenmiş ve bir kayıt kimliği oluşturulmuşsa tekrar yükleme yapılmadan mevcut kayıt üzerinden devam edilir. Ardından iki model için ayrı işlem istekleri gönderilir. Sol ve sağ panel işlemleri paralel olarak yürütülür; bir modelden hata alınsa bile diğerinin sonucu başarılıysa ekranda gösterilebilir. Her model için ayrı bir işlem kaydı oluşturulur ve çıktı dosyası bağımsız olarak saklanır. Her iki model çıktısı da bağımsız ses oynatıcı olarak davranır; kullanıcı istediği paneli ayrı ayrı dinleyebilir ve indirebilir.


Hata Durumları

Sol veya sağ modelden biri hata üretirse ilgili panelde işlemin başarısız olduğuna dair bildirim gösterilir. Diğer modelin sonucu başarılıysa o panelde gösterim sürer. Her iki model de başarısız olursa kullanıcıya karşılaştırmanın tamamlanamadığına dair genel bir uyarı iletir.

Bu yapı, model bazlı hata ayrımı yapabildiğinden hangi modelin sorun ürettiğini hızlı biçimde tespit etmeyi kolaylaştırır.

Kullanım Amacı

Model karşılaştırma ekranı özellikle deneysel değerlendirme ve model seçimi süreçleri için tasarlanmıştır. Aynı giriş sesinin farklı modellerden elde edilen temizlenmiş halleri yan yana dinlenerek modeller arasındaki performans farkları doğrudan gözlemlenebilir. Proje kapsamında geliştirilen FRCRN, GTCRN, FullSubNet+, SGMSE+ ve MossFormerGAN modelleri bu ekran üzerinden kolayca karşılaştırılabilir. Örneğin bir model konuşmayı daha doğal ve yapay bozulmasız bırakırken başka bir model arka plan gürültüsünü daha agresif biçimde bastırıyor olabilir. Bu ekran, söz konusu farkların hızla gözlemlenmesini ve kullanım amacına en uygun modelin belirlenmesini kolaylaştırmaktadır.



Şekil 3.4. Model Karşılaştırma Ekranı

3.2.3. Geçmiş Ekranı

Geçmiş ekranı, kullanıcının daha önce gerçekleştirdiği ses temizleme işlemlerini listeleyen ve tamamlanmış kayıtları yeniden incelemeye açan bölümdür. Bu ekran sayesinde kullanıcı geçmiş çıktılarına tekrar ulaşabilir, orijinal ve temizlenmiş sesleri karşılaştırabilir, sonuçları farklı görsel modlarda analiz edebilir ve istemediği kayıtları silebilir.

Eriřim Mantığı

Geçmiş ekranı yalnızca oturum açmış kullanıcılar için görünür. Kullanıcı giriş yapmamışsa bu bölüm ekranda gösterilmez. Sistem geçmiş kayıtlarını kullanıcının hesabına bağılı olarak arka uçtan alır; böylece her kullanıcı yalnızca kendi işlem geçmişini görüntüler.

Kayıtların Listelenmesi

Ekran açıldığında kullanıcının ses işleme kayıtları tarih sırasına göre en yeniden en eskiye doğru listelenir. Her kayıt kartında kullanılan model adı, işlem tarihi ve işlem durumu gösterilir. Tarih bilgisi okunabilir Türkçe formatta sunulur. Kayıt durumları rozetlerle görsel olarak ayrıştırılır: bekliyor, işleniyor, tamamlandı ve hata durumları farklı biçimlerde gösterilir. Tamamlanmamış veya hatalı kayıtlar pasif görünür ve bu kayıtlar detay inceleme alanında açılmaz.

Kayıt Seçme ve İnceleme

Tamamlanmış bir kayda tıklandığında ekranın üst bölümünde detaylı inceleme alanı açılır. Seçilen kayıt görsel olarak vurgulanır. Başka bir kayıt seçildiğinde inceleme alanı yeni kaydın orijinal ve temizlenmiş ses dosyalarıyla güncellenir. Varsayılan inceleme modu dalga formu görünümüdür. Kullanıcı isterse aynı kayıt için spektrogram veya 3D görünüm moduna geçebilir.

Dalga Formu İncelemesi

Dalga formu görünümünde orijinal ses ve temizlenmiş ses karşılaştırmalı olarak sunulur. Kullanıcı iki sesi dinleyebilir, duraklatabilir ve başa alabilir. Temizlenmiş ses için indirme seçeneğı de mevcuttur. Bu görünüm sesin zaman içindeki genlik değişimini incelemek ve temizleme sonrasındaki farkları gözlemlemek için kullanılır. Dalga formu örtüşme alanı açıldığında orijinal ve temizlenmiş sinyal aynı grafik üzerinde çakıştırılarak karşılaştırma daha kolay yapılabilir.

Spektrogram İncelemesi

Spektrogram görünümü seçilen geçmiş kaydının frekans-zaman analizini gösterir. Orijinal ses ve temizlenmiş ses ayrı panellerde yer alır. Kullanıcı bu panellerde sesi dinleyebilir ve fare hareketleriyle spektrogram üzerinde gezinerek ilgili noktanın zaman ve frekans bilgisini anlık


olarak görebilir. Konuşma bandı özelliği etkinleştirildiğinde görünüm yalnızca insan konuşması için kritik frekans aralığına odaklanır. Ayrıca orijinal ve temizlenmiş spektrogramların yan yana yerleştirildiği birleşik görsel PNG formatında indirilebilir.

3D Görünüm İncelemesi

3D görünüm sekmesi seçilen geçmiş kaydını enerji haritası olarak üç boyutlu biçimde sunar. Kullanıcı sahneyi fareyle döndürebilir, yakınlaştırabilir ve farklı açılardan inceleyebilir. Orijinal enerji, temizlenmiş enerji ve fark görünümü arasında geçiş yapılabilir. Bu sayede temizleme işleminin enerji dağılımında oluşturduğu değişim görsel olarak değerlendirilebilir.

Yenileme ve Kayıt Silme

Geçmiş ekranındaki yenileme butonu listeyi arka uçtan tekrar çekerek güncel kayıt durumlarını ekrana yansıtır. Özellikle yakın zamanda tamamlanan veya silinen işlemlerin ardından listeyi güncellemek için kullanılır. Her kayıt kartında silme butonu bulunur; butona basıldığında onay penceresi gösterilir ve onay verilmesi halinde ilgili kayıt silinir. Silinen kayıt o an seçili kayıtsa ekran otomatik olarak başka bir tamamlanmış kayda geçer; uygun kayıt yoksa detay alanı kapanır. Silme işlemi yalnızca liste kaydını değil ilgili ses dosyasını da kaldırır; orijinal ses başka bir kayıt tarafından kullanılmıyorsa o dosya da sistemden temizlenerek gereksiz dosya birikimi önlenir.



Şekil 3.5. Geçmiş Ekranı

4. TEST VE DOĞRULAMA

4.1. Test ve Hata Giderme Mekanizmaları

Proje geliştirme sürecinde model eğitiminin kararlılığını ve gürültü giderme pipeline'ının doğruluğunu değerlendirmek için farklı test mekanizmaları uygulanmıştır. Eğitim sürecinde her epoch sonunda doğrulama yapılmış; model başarısı SI-SDR, val loss ve erken durdurma sayacı üzerinden takip edilmiştir. Eğitim sırasında loss değerleri, GPU bellek kullanımı, atlanan batch sayısı ve öğrenme oranı değişimleri izlenerek olası sayısal kararsızlıklar, bellek taşmaları ve öğrenme sorunları tespit edilmiştir.

Manuel test aşamasında eğitilen modeller farklı gürültü koşullarındaki Türkçe ses örnekleri üzerinde denenmiş ve model çıktıları hem nesnel metriklerle hem de kulak testiyle değerlendirilmiştir. Bu testlerde modelin gürültüyü ne kadar temizlediği, konuşma bileşenlerini koruyup korumadığı ve yapay bozulma üretip üretmediği incelenmiştir.

4.2. Geliştirme Sürecinde Karşılaşılan Hatalar ve Çözümleri

FullSubNet+ cIRM Maskeleye Yanlılığı

- **Tanımlanan Sorun:** Model çıktısı [B, 2, F, T] formatında real ve imag bileşenlerinden oluşmaktaydı. Ancak enhance_batch içinde bu çıktı decompress_cIRM ile işlenerek noisy spektrograma uygulanmaya çalışılmış; bu hem boyut uyumsuzluğuna hem de SI-SDR'ın negatif kalmasına yol açmıştır. Sorunun kökü modelin cIRM maskesi değil doğrudan enhanced spektrogram ürettiğinin anlaşılmasıydı.
- **Uygulanan Çözüm:** Teşhis testleriyle model çıktısının ölçek aralığı incelenmiş; noisy_complex değerlerinin -65 ile +45 arasında, model çıktısının ise -0.6 ile +3.7 arasında olduğu görülmüştür. Bu fark modelin bir maske ürettiğini doğrulamıştır. Maskeleme formülü doğru biçimde uygulanmış; enhanced_real = mask_real * noisy_real - mask_imag * noisy_imag hesabıyla SI-SDR 9.95 dB'den 12.38 dB'ye yükselmiştir.

MossFormerGAN drop_band Frekans Boyutu Uyumsuzluğu

- **Tanımlanan Sorun:** SyncANet forward kodunda batch_size > 1 olduğunda drop_band aktif hale gelmekte ve frekans boyutunu F=257'den F=128'e düşürmektedir. Bu durum enhance_batch içinde full frekans boyutu bekleyen iSTFT işlemiyle uyumsuzluğa yol açmış ve RuntimeError üretmiştir.
- **Uygulanan Çözüm:** Çıkarım sırasında her örnek batch_size=1 ile ayrı ayrı işlenmiştir. batch_size=1 olduğunda drop_band devreye girmemekte ve model tam F=257 frekans çıktısı üretmektedir. Aynı yaklaşım forward_loss içinde de uygulanmış; her batch elemanı döngü içinde batch_size=1 ile modelden geçirilmiştir.

MossFormerGAN Pretrained Checkpoint Boyut Uyumsuzluğu

- **Tanımlanan Sorun:** fft_len=400 parametresiyle kurulan model, pretrained checkpoint'teki ağırlık boyutlarıyla (attn_conv_Q.2.gamma: [1, 6, 1, 101]) uyuşmamıştır. Modelin fft_len=200 ile eğitilmiş olduğu anlaşılmıştır.
- **Uygulanan Çözüm:** Pretrained ağırlıklardaki gamma boyutları incelenerek gerçek fft_len değeri tersine mühendislikle bulunmuştur. STFT parametreleri fft_len=400, win_len=400, hop_len=100, center=False olarak ayarlanmış; doğru chunk boyutu

(20.400 örnek) deneme yanılma yöntemiyle tespit edilmiştir. Sonucunda missing=0, unexpected=0 ile eksiksiz checkpoint yüklemesi sağlanmıştır.

Eğitim Loss'larının NaN Üretmesi

- **Tanımlanan Sorun:** İlk eğitim denemelerinde train loss nan olarak raporlanmıştır. Model AMP (mixed precision) etkinken kompleks tensör işlemlerinde sayısal kararsızlık yaşamış; bazı modellerde forward_loss içinde AMP kapsamının yanlış belirlenmesi nan üretimine yol açmıştır.
- **Uygulanan Çözüm:** AMP devre dışı bırakılarak eğitim float32 modunda yeniden başlatılmıştır. STFT ve loss hesapları AMP dışında tutulmuş, yalnızca model forward işlemi AMP kapsamına alınmıştır. torch.clamp ile cIRM değerleri [-10, 10] aralığıyla sınırlandırılmıştır. NaN üreten batch'lerin optimizer.zero_grad() ve torch.cuda.empty_cache() çağrılarıyla güvenli biçimde atlanması sağlanmıştır.

4.3. Genel Değerlendirme

Proje sürecinde karşılaşılan hatalar, model eğitiminin ötesinde ortam kurulumu, veri hazırlama, checkpoint uyumluluğu, framework API değişiklikleri ve bulut altyapısı sınırlamaları gibi çok sayıda teknik katmanı kapsadığını göstermiştir. Her hata sistematik teşhis adımlarıyla ele alınmış; hook tabanlı NaN tespiti, boyut doğrulama testleri ve adım adım forward analizi gibi yöntemlerle sorunların kök nedeni belirlenmiştir. Bu süreç, model mimarisinin doğru anlaşılmasının ve veri pipeline'ının eksiksiz tasarlanmasının eğitim başarısı üzerindeki belirleyici etkisini açıkça ortaya koymuştur.

5. SONUÇ

Proje sürecinde temel hedefimiz olan Türkçe konuşma seslerindeki arka plan gürültüsünün derin öğrenme tabanlı yöntemlerle giderilmesi, çok aşamalı bir yapay zeka süreci ile ele alınmıştır. Bu kapsamda proje yalnızca belirli bir modeli Türkçe veri üzerinde çalıştırmayı amaçlayan tekil bir uygulama olarak değerlendirilmemiştir. Bunun yerine, farklı model mimarilerinin aynı koşullar altında karşılaştırmalı olarak değerlendirilebileceği sistematik bir eğitim, doğrulama ve analiz işlem hattı oluşturulmuştur.

İlk aşamada gürültü giderme modellerinin Türkçe sesle çalışabilmesi için uygun bir veri kümesi hazırlanması gerekmiştir. Bu amaçla Google FLEURS tr_tr ve CommonVoice 17 TR veri kümeleri birleştirilerek yaklaşık 14.000 eşsiz temiz Türkçe ses dosyası derlenmiştir. Veri seçiminde tekrarlı örneklemenin overfite yol açabileceği öngörüsüyle FLEURS'un tüm eşsiz örnekleri kullanılmış, kalan kota CommonVoice'ın geniş konuşmacı çeşitliliğinden yararlanılarak karşılanmıştır. Tüm ses dosyaları 16 kHz örnekleme hızına dönüştürülmüş, mono kanala indirgenmiş ve tepe normalizasyonu uygulanmıştır. Gürültü augmentation aşamasında Microsoft DNS Challenge 4 veri kümesinden elde edilen gerçek ortam gürültüleri altı farklı SNR seviyesinde temiz seslerle on-the-fly karıştırılmıştır. Bu yaklaşım sayesinde gürültülü-temiz çiftleri eğitim öncesinde diske yazılmadan her eğitim adımında dinamik biçimde üretilmiş; veri çeşitliliği artırılırken depolama maliyeti minimize edilmiştir.

Model geliştirme sürecinde beş farklı mimari değerlendirilmiştir. Pretrained ağırlıklarla başlatılan FullSubNet+ ve MossFormerGAN modelleri fine-tuning stratejisiyle Türkçe veriye uyarlanmıştır. Pretrained başlangıcın sağladığı avantaj sayesinde bu modeller görece az epoch ile iyi sonuçlara ulaşmıştır. Sıfırdan eğitilen FRCRN ve GTCRN modelleri ise daha uzun eğitim süreçlerine rağmen pretrained modellerle rekabetçi sonuçlar üretebilmiştir. Bu durum, mimari tasarım ve loss fonksiyonu seçiminin pretrained ağırlık avantajını kısmen telafi edebildiğini ortaya koymuştur.

SGMSE+ ise sıfırdan eğitilen difüzyon tabanlı model olarak değerlendirilmiş; SI-SDR delta açısından grubun en yüksek iyileştirmesini elde etmiştir. Buna karşın PESQ değerinin daha düşük kalması, difüzyon tabanlı yaklaşımın daha uzun eğitim, daha büyük veri veya farklı perceptual loss bileşenleriyle desteklenmesi gerektiğini göstermiştir.

Eğitim sürecinde çeşitli teknik güçlüklerle karşılaşmıştır. Model mimarilerinin iç yapılarının yeterince anlaşılmaması bazı durumlarda yanlış maskeleme uygulamalarına ve beklentinin aksine düşük performans çıktılarına yol açmıştır. Pretrained checkpoint ağırlıklarının modelin beklediği parametre yapısıyla uyuşmaması durumunda sistematik teşhis yöntemleriyle kök neden belirlenmiş ve hedefli çözümler uygulanmıştır. Gürültülü veri hazırlama aşamasında veri kaydetme hatalarının model performansını doğrudan etkilediği de bu süreçte görülmüştür; FRCRN modelinde tespit edilen sabit segment dolgusu hatasının düzeltilmesi PESQ ve STOI metriklerinde ölçülebilir iyileşme sağlamıştır. Bunun yanında Google Colab'ın 24 saatlik runtime sınırı ve Drive yazma darboğazı gibi altyapı kısıtlamaları da eğitim süreçlerini

doğrudan etkilemiştir. Bu sorunlar, checkpoint tabanlı kurtarma mekanizmaları ve veri akışının Drive yerine local diske yönlendirilmesiyle aşılmıştır.


Değerlendirme aşamasında tüm modeller aynı test seti ve aynı metriklerle değerlendirilmiştir. SI-SDR, PESQ ve STOI metrikleri birlikte kullanılarak modellerin hem matematiksel hem de algısal performansı kapsamlı biçimde ölçülmüştür. Sonuçlar incelendiğinde MossFormerGAN'ın PESQ 2.633 ve STOI 0.934 ile algısal kalite açısından grubun en üstün modeli olduğu görülmüştür. GAN bileşeninin algısal kaliteye sağladığı katkı hem nesnel metrikler hem de kulak testi yoluyla doğrulanmıştır. SI-SDR delta açısından ise FRCRN ve GTCRN öne çıkmış; bu modellerin loss fonksiyonlarında sinyal-gürültü oranı optimizasyonuna daha fazla ağırlık verilmesinin bu metriğe doğrudan yansıdığı görülmüştür. GTCRN yalnızca 6.9 milyon parametreyle sıfırdan eğitilmiş olmasına karşın 8.6 milyon parametrelili ve pretrained ağırlıklara sahip FullSubNet+'a yakın algısal metrikler elde etmiş; bu sonuç parametre sayısından bağımsız olarak mimari tasarım ve eğitim stratejisinin belirleyici rolünü ortaya koymuştur.

DNS Challenge referans değerleriyle yapılan karşılaştırmada projemizin modellerinin SI-SDR açısından uluslararası benchmark değerlerine yakın sonuçlar ürettiği görülmüştür. PESQ açısından ise belirli bir fark bulunmaktadır; ancak bu farkın büyük bölümünün veri miktarı asimetrisiyle açıklanabileceği değerlendirilmektedir. DNS Challenge modelleri on binlerce saatlik İngilizce veriyle eğitilirken projemizin modelleri yaklaşık 15-20 saatlik Türkçe veriyle eğitilmiştir. Daha büyük Türkçe veri kümeleriyle yapılacak eğitimlerin bu farkı önemli ölçüde kapatacağı öngörülmektedir.


5.1. Modellerin Test Çıktıları

Modellerin gürültü giderme performansını görsel olarak da inceleyebilmek amacıyla seçilen test ses örneklerine ait spektrogramlar aşağıda sunulmuştur. Spektrogram, bir ses sinyalinin zaman eksenini boyunca frekans bileşenlerinin yoğunluğunu gösteren iki boyutlu bir görsel temsil biçimidir. Bu görsellerde yatay eksen zamanı, dikey eksen frekansı, renk yoğunluğu ise ilgili frekanstaki enerji düzeyini ifade etmektedir. Gürültülü giriş, model çıktısı ve referans temiz ses spektrogramlarının yan yana incelenmesi; modelin hangi frekans bölgelerinde gürültüyü başarıyla bastırdığını, konuşma bileşenlerini ne ölçüde koruduğunu ve yapay bozulma üretip üretmediğini görsel olarak ortaya koymaktadır.

Orijinal Ses
Spektrogram görünümü




Temizlenmiş Ses
Spektrogram görünümü




Şekil 5.1. FullSubNet+ Spektrogram Sonuçları

Orijinal Ses
Spektrogram görünümü



Temizlenmiş Ses
Spektrogram görünümü




Şekil 5.2. MossFormerGAN Spektrogram Sonuçları

Orijinal Ses
Spektrogram görünümü




Temizlenmiş Ses
Spektrogram görünümü




Şekil 5.3. GTCRN Spektrogram Sonuçları

Orijinal Ses
Spektrogram görünümü




Temizlenmiş Ses
Spektrogram görünümü




Şekil 5.4. FRCRN Spektrogram Sonuçları

Orijinal Ses
Spektrogram görünümü



Temizlenmiş Ses
Spektrogram görünümü



Şekil 5.5. SGMSE+ Spektrogram Sonuçları

5.2. Genel Kazanımlar

Test sonuçları, eğitilen modellerin Türkçe konuşma seslerindeki arka plan gürültüsünü anlamlı ölçüde azaltabildiğini ve konuşma bileşenlerini büyük ölçüde koruduğunu göstermektedir. Özellikle MossFormerGAN ve FullSubNet+ modellerinin algısal kalite metriklerinde elde ettiği sonuçlar, pretrained ağırlıklarla başlatılan fine-tuning stratejisinin sınırlı Türkçe veriyle bile etkili sonuçlar üretebileceğini ortaya koymaktadır.

- Gürültülü ses dosyaları modele beslenerek temizlenmiş ses gerçek zamanlı olarak üretilmektedir.

- Farklı gürültü türleri ve SNR seviyelerinde tutarlı iyileştirme sağlanmış; özellikle orta ve yüksek SNR aralıklarında konuşma anlaşılabilirliği belirgin biçimde artmıştır.
- Beş farklı mimari aynı veri ve metriklerle karşılaştırılmış; her modelin güçlü olduğu senaryo belirlenmiş ve kullanım amacına göre model seçimi için somut bir rehber oluşturulmuştur.

5.3. GitHub

Bu projenin geliştirme süreci, versiyon kontrol sistemi olarak Git kullanılarak yönetilmektedir ve tüm proje bileşenleri GitHub platformu üzerinde saklanmaktadır. GitHub deposu sayesinde proje süreci şeffaf bir şekilde takip edilebilmekte, yapılan geliştirmeler ve güncellemeler commit geçmişi üzerinden incelenebilmektedir.

Proje kapsamında geliştirilen tüm kodlar, veri işleme adımları, model eğitim süreçleri ve kullanıcı arayüzü bileşenleri ilgili GitHub deposunda düzenli bir klasör yapısı altında tutulmaktadır. Bu yapı sayesinde hem ekip içi iş birliği kolaylaştırılmakta hem de projenin sürdürülebilirliği sağlanmaktadır.

<https://github.com/bilalcetinn/sless>

6. KAYNAKLAR

FullSubNet+: <https://arxiv.org/pdf/2203.12188>

GTCRN: <https://github.com/Xiaobin-Rong/gtcn>

FRCRN: <https://github.com/alibabasglab/FRCRN>

MossFormerGAN: <https://github.com/modelscope/ClearerVoice-Studio>

SGMSE+: <https://github.com/sp-uhh/sgmse>

Parametre İncelemeleri: <https://medium.com/deep-learning-turkiye/derin-ogrenme-uygulamalarinda-en-sik-kullanilan-hiper-parametreler-ece8e9125c4>

Metrikler PESQ:

https://lightning.ai/docs/torchmetrics/stable/audio/perceptual_evaluation_speech_quality.html

Metrikler SI-SDR:

https://lightning.ai/docs/torchmetrics/stable/audio/scale_invariant_signal_distortion_ratio.html

Metrikler STOI: <https://dergipark.org.tr/en/download/article-file/4892121>